

TEMA 2: Estadística descriptiva bidimensional

- Distribución conjunta de dos variables estadísticas. Tablas y representaciones gráficas.
- Distribuciones marginales.
- Distribuciones condicionadas.
- Dependencia funcional. Dependencia e independencia estadística.
- Momentos bidimensionales.
- Regresión y correlación:
 - Ajuste de funciones por mínimos cuadrados. Curvas y rectas de regresión.
 - Razón de correlación. Correlación lineal.

DISTRIBUCIÓN CONJUNTA DE DOS CARACTERES

Consideramos una población formada por n individuos en la que se estudian simultáneamente dos variables (atributos), X e Y , con valores (modalidades) x_1, \dots, x_k e y_1, \dots, y_p , respectivamente.

■ **Frecuencia absoluta del par (x_i, y_j) :**

n_{ij} = número de individuos de la población que presentan simultáneamente los valores (modalidades) x_i de X e y_j de Y .

Distribución de frecuencias absolutas: $\left\{((x_i, y_j), n_{ij}); i = 1, \dots, k, j = 1, \dots, p\right\}$

$$\sum_{i=1}^k \sum_{j=1}^p n_{ij} = n.$$

■ **Frecuencia relativa del par (x_i, y_j) :**

f_{ij} = proporción de individuos de la población que presentan simultáneamente los valores (modalidades) x_i de X e y_j de $Y \longrightarrow f_{ij} = \frac{n_{ij}}{n}$.

Distribución de frecuencias relativas: $\left\{((x_i, y_j), f_{ij}); i = 1, \dots, k, j = 1, \dots, p\right\}$


$$\sum_{i=1}^k \sum_{j=1}^p f_{ij} = 1.$$

Tabla de frecuencias bidimensionales

$X \setminus Y$	y_1	\dots	y_j	\dots	y_p
x_1	n_{11}	\dots	n_{1j}	\dots	n_{1p}
\vdots	\vdots	\dots	\vdots	\dots	\vdots
x_i	n_{i1}	\dots	n_{ij}	\dots	n_{ip}
\vdots	\vdots	\dots	\vdots	\dots	\vdots
x_k	n_{k1}	\dots	n_{kj}	\dots	n_{kp}


REPRESENTACIONES GRÁFICAS

- **Diagrama de dispersión o nube de puntos** (*datos cuantitativos*): Se representa cada par de observaciones (o marcas de clase, si los datos están agrupados en intervalos) (x_i, y_j) en un sistema de ejes cartesianos. Si un par tiene frecuencia mayor que uno, ésta puede indicarse al lado del punto correspondiente:



- **Estereograma:** gráfico tridimensional formado por barras o prismas según los casos:
 - *Variables discretas:* barras verticales de longitudes iguales (o proporcionales) a las frecuencias de cada par de valores, que se representan en el plano base.
 - *Caracteres cualitativos:* prismas con base común y alturas iguales (o proporcionales) a las frecuencias de cada par de modalidades, representadas en el plano base.
 - *Variables continuas:* prismas con bases definidas por cada par de intervalos y alturas iguales (o proporcionales) a las *densidades de frecuencia*, de forma que el volumen de cada prisma es igual (o proporcional) a la frecuencia de la pareja de intervalos correspondiente.

$$h_{ij} = \frac{n_{ij}}{(e_i^x - e_{i-1}^x)(e_j^y - e_{j-1}^y)}$$



DISTRIBUCIONES MARGINALES

$$\left\{ ((x_i, y_j), n_{ij}); i = 1, \dots, k, j = 1, \dots, p \right\}, \quad n = \sum_{i=1}^k \sum_{j=1}^p n_{ij}, \quad f_{ij} = \frac{n_{ij}}{n}$$

Frecuencia absoluta del valor (modalidad) x_i del carácter X : número de individuos que presentan dicho valor (sin tener en cuenta el que presentan en Y):

$$n_{i.} = \sum_{j=1}^p n_{ij} ; \quad i = 1, 2, \dots, k \quad \longrightarrow \quad \sum_{i=1}^k n_{i.} = n$$

Frecuencia relativa del valor (modalidad) x_i del carácter X : proporción de individuos que presentan dicho valor (sin tener en cuenta el que presentan en Y):

$$f_{i.} = \frac{n_{i.}}{n} = \sum_{j=1}^p f_{ij} ; \quad i = 1, 2, \dots, k \quad \longrightarrow \quad \sum_{i=1}^k f_{i.} = 1$$

Distribución marginal de X : $\{(x_i, n_{i.}), i = 1, 2, \dots, k\} \equiv \{(x_i, f_{i.}), i = 1, 2, \dots, k\}$

Frecuencia absoluta del valor (modalidad) y_j del carácter Y : número de individuos que presentan dicho valor (sin tener en cuenta el que presentan en X):

$$n_{.j} = \sum_{i=1}^k n_{ij} ; \quad j = 1, 2, \dots, p \quad \longrightarrow \quad \sum_{j=1}^p n_{.j} = n$$

Frecuencia relativa del valor (modalidad) y_j del carácter Y : proporción de individuos que presentan dicho valor (sin tener en cuenta el que presentan en X):

$$f_{.j} = \frac{n_{.j}}{n} = \sum_{i=1}^k f_{ij} ; \quad j = 1, 2, \dots, p \quad \longrightarrow \quad \sum_{j=1}^p f_{.j} = 1$$

Distribución marginal de Y : $\{(y_j, n_{.j}), j = 1, 2, \dots, p\} \equiv \{(y_j, f_{.j}), j = 1, 2, \dots, p\}$

$X \setminus Y$	y_1	\dots	y_j	\dots	y_p	Sumas
x_1	n_{11}	\dots	n_{1j}	\dots	n_{1p}	$\mathbf{n_{1.}}$
\vdots	\vdots	\dots	\vdots	\dots	\vdots	\vdots
x_i	n_{i1}	\dots	n_{ij}	\dots	n_{ip}	$\mathbf{n_{i.}}$
\vdots	\vdots	\dots	\vdots	\dots	\vdots	\vdots
x_k	n_{k1}	\dots	n_{kj}	\dots	n_{kp}	$\mathbf{n_{k.}}$
Sumas	$\mathbf{n_{.1}}$	\dots	$\mathbf{n_{.j}}$	\dots	$\mathbf{n_{.p}}$	n

$$\bar{x} = \sum_{i=1}^k f_{i.} x_i, \quad \sigma_x^2 = \sum_{i=1}^k f_{i.} (x_i - \bar{x})^2$$

$$\bar{y} = \sum_{j=1}^p f_{.j} y_j, \quad \sigma_y^2 = \sum_{j=1}^p f_{.j} (y_j - \bar{y})^2$$

DISTRIBUCIONES CONDICIONADAS

$X \setminus Y$	y_1	\cdots	y_j	\cdots	y_p	$n_{i.}$
x_1	n_{11}	\cdots	n_{1j}	\cdots	n_{1p}	$n_{1.}$
\vdots	\vdots	\cdots	\vdots	\cdots	\vdots	\vdots
x_i	n_{i1}	\cdots	n_{ij}	\cdots	n_{ip}	$n_{i.}$
\vdots	\vdots	\cdots	\vdots	\cdots	\vdots	\vdots
x_k	n_{k1}	\cdots	n_{kj}	\cdots	n_{kp}	$n_{k.}$
$n_{.j}$	$n_{.1}$	\cdots	$n_{.j}$	\cdots	$n_{.p}$	n

Distribución condicionada de X a $Y = y_j$; $j = 1, \dots, p$



Sólo se consideran los $n_{.j}$ individuos que presentan el valor (o modalidad) y_j en el carácter Y (columna j -ésima).

- Frecuencia absoluta de x_i en los individuos tales que $Y = y_j \rightarrow n_{ij}$, $i = 1, \dots, k$.
- Frecuencia relativa de x_i en los individuos tales que $Y = y_j \rightarrow f_{i/j} = \frac{n_{ij}}{n_{.j}}$, $i = 1, \dots, k$.

$X/Y = y_j$	n_{ij}	$f_{i/j}$	$\bullet f_{i/j} = \frac{n_{ij}}{n_{.j}} = \frac{f_{ij}}{f_{.j}} \rightarrow f_{ij} = f_{i/j} f_{.j}, i = 1, \dots, k, j = 1, \dots, p.$
x_1	n_{1j}	$f_{1/j}$	
\vdots	\vdots	\vdots	
x_i	n_{ij}	$f_{i/j}$	
\vdots	\vdots	\vdots	
x_k	n_{kj}	$f_{k/j}$	
Sumas	$n_{.j}$	1	

Media condicionada: $\bar{x}_j = \sum_{i=1}^k f_{i/j} x_i$

Varianza condicionada: $\sigma_{x,j}^2 = \sum_{i=1}^k f_{i/j} (x_i - \bar{x}_j)^2$

$$\bar{x} = \sum_{j=1}^p f_{.j} \bar{x}_j, \quad \sigma_x^2 = \sum_{j=1}^p f_{.j} \sigma_{x,j}^2 + \sum_{j=1}^p f_{.j} (\bar{x}_j - \bar{x})^2$$

Distribución condicionada de Y a $X = x_i$; $i = 1, \dots, k$



Sólo se consideran los $n_{i.}$ individuos que presentan el valor (o modalidad) x_i en el carácter X (fila i -ésima).

- Frecuencia absoluta de y_j en los individuos tales que $X = x_i \rightarrow n_{ij}$, $j = 1, \dots, p$
- Frecuencia relativa de y_j en los individuos tales que $X = x_i \rightarrow f_{j/i} = \frac{n_{ij}}{n_{i.}}$, $j = 1, \dots, p$

$Y/X = x_i$	n_{ij}	$f_{j/i}$	$\bullet f_{j/i} = \frac{n_{ij}}{n_{i.}} = \frac{f_{ij}}{f_{i.}} \rightarrow f_{ij} = f_{j/i} f_{i.}, i = 1, \dots, k, j = 1, \dots, p.$
y_1	n_{i1}	$f_{1/i}$	
\vdots	\vdots	\vdots	
x_j	n_{ij}	$f_{j/i}$	
\vdots	\vdots	\vdots	
y_p	n_{ip}	$f_{p/i}$	
Sumas	$n_{i.}$	1	

Media condicionada: $\bar{y}_i = \sum_{j=1}^p f_{j/i} y_j$

Varianza condicionada: $\sigma_{y,i}^2 = \sum_{j=1}^p f_{j/i} (y_j - \bar{y}_i)^2$


$$\bar{y} = \sum_{i=1}^k f_{i.} \bar{y}_i, \quad \sigma_y^2 = \sum_{i=1}^k f_{i.} \sigma_{y,i}^2 + \sum_{i=1}^k f_{i.} (\bar{y}_i - \bar{y})^2$$

DEPENDENCIA FUNCIONAL Y DEPENDENCIA ESTADÍSTICA

DEPENDENCIA FUNCIONAL


Un carácter X depende funcionalmente de un carácter Y si la modalidad que presenta cada individuo en Y determina la que presenta en X (para cada modalidad de Y sólo hay una modalidad de X con frecuencia no nula). Para caracteres cuantitativos, $X = f(Y)$:

$X \setminus Y$	y_1	y_2	y_3	y_4	y_5
x_1	n_{11}	0	n_{13}	0	0
x_2	0	n_{22}	0	0	n_{25}
x_3	0	0	0	n_{34}	0



DEPENDENCIA ESTADÍSTICA

Un carácter X es estadísticamente dependiente de un carácter Y si el comportamiento de X es diferente según las modalidades de Y :



DEPENDENCIA FUNCIONAL \Rightarrow DEPENDENCIA ESTADÍSTICA
 \nLeftarrow

Un carácter X es estadísticamente independiente de un carácter Y si el comportamiento de X es el mismo para todas las modalidades de Y (propiedad recíproca). En tal caso, el diagrama de dispersión es un rectángulo (condición necesaria para la independencia):



INDEPENDENCIA ESTADÍSTICA

$$\left\{ ((x_i, y_j), n_{ij}); i = 1, \dots, k, j = 1, \dots, p \right\} \quad n = \sum_{i=1}^k \sum_{j=1}^p n_{ij}, \quad f_{ij} = \frac{n_{ij}}{n}$$

$$\blacksquare n_{i.} = \sum_{j=1}^p n_{ij}, \quad i = 1, \dots, k; \quad n_{.j} = \sum_{i=1}^k n_{ij}, \quad j = 1, \dots, p$$

$$\blacksquare f_{i.} = \frac{n_{i.}}{n}, \quad i = 1, \dots, k; \quad f_{.j} = \frac{n_{.j}}{n}, \quad j = 1, \dots, p$$

$$\blacksquare f_{i/j} = \frac{n_{ij}}{n_{.j}} = \frac{f_{ij}}{f_{.j}}; \quad f_{j/i} = \frac{n_{ij}}{n_{i.}} = \frac{f_{ij}}{f_{i.}}, \quad i = 1, \dots, k, \quad j = 1, \dots, p$$

- El carácter X es (estadísticamente) independiente del carácter Y si las distribuciones de X condicionadas a cada modalidad de Y coinciden:

$$\forall i = 1, \dots, k, \quad f_{i/j} \text{ no depende de } j \quad (f_{i/1} = f_{i/2} = \dots = f_{i/p}, \quad \forall i = 1, \dots, k).$$

- Similarmente, Y es (estadísticamente) independiente de X si las distribuciones de Y condicionadas a cada modalidad de X coinciden:

$$\forall j = 1, \dots, p, \quad f_{j/i} \text{ no depende de } i \quad (f_{j/1} = f_{j/2} = \dots = f_{j/k}, \quad \forall j = 1, \dots, p).$$

Caracterizaciones de independencia:

- X es independiente de Y si y sólo si la distribución condicionada de X a cualquier modalidad de Y coincide con la distribución marginal de X :

$$X \text{ es independiente de } Y \Leftrightarrow f_{i/j} = f_{i.}, \quad \forall i = 1, \dots, k, \quad \forall j = 1, \dots, p.$$

- X es independiente de Y si y sólo si Y es independiente de X .

- X e Y son independientes $\Leftrightarrow f_{ij} = f_{i.} f_{.j}, \quad \forall i = 1, \dots, k, \quad \forall j = 1, \dots, p$

$$\Leftrightarrow n_{ij} = \frac{n_{i.} n_{.j}}{n}, \quad \forall i = 1, \dots, k, \quad \forall j = 1, \dots, p.$$

MOMENTOS BIDIMENSIONALES

$$\left\{ ((x_i, y_j), n_{ij}); i = 1, \dots, k, j = 1, \dots, p \right\} \quad n = \sum_{i=1}^k \sum_{j=1}^p n_{ij}, \quad f_{ij} = \frac{n_{ij}}{n}$$

Valores numéricos o marcas de clase

Momentos conjuntos no centrados (centrados en el origen)

$$m_{rs} = \sum_{i=1}^k \sum_{j=1}^p f_{ij} x_i^r y_j^s, \quad r, s \in \mathbb{N} \cup \{0\} \quad (*)$$



Momentos no centrados marginales:

- $m_{r0} = \sum_{i=1}^k f_{i.} x_i^r$
- $m_{0s} = \sum_{j=1}^p f_{.j} y_j^s$

Momentos conjuntos centrados (centrados en medias)

$$\mu_{rs} = \sum_{i=1}^k \sum_{j=1}^p f_{ij} (x_i - \bar{x})^r (y_j - \bar{y})^s, \quad r, s \in \mathbb{N} \cup \{0\} \quad (*)$$



Momentos centrados marginales:

- $\mu_{r0} = \sum_{i=1}^k f_{i.} (x_i - \bar{x})^r$
- $\mu_{0s} = \sum_{j=1}^p f_{.j} (y_j - \bar{y})^s$

Momentos de primer y segundo orden:

- Medias marginales: $m_{10} = \bar{x}$, $m_{01} = \bar{y}$.
- Varianzas marginales: $\mu_{20} = \sigma_x^2$, $\mu_{02} = \sigma_y^2$.
- Covarianza de las variables X e Y : $\mu_{11} = \sigma_{xy} = \text{Cov}(X, Y)$.

Propiedades de los momentos:

- $\sigma_{xy} = \mu_{11} = m_{11} - m_{10}m_{01}$.
- X e Y estadísticamente independientes $\implies \left\{ \begin{array}{l} m_{rs} = m_{r0}m_{0s} \\ \mu_{rs} = \mu_{r0}\mu_{0s} \\ \text{Cov}(X, Y) = \sigma_{xy} = 0. \end{array} \right.$

(*) Convenio: $0^0 = 1$

PROBLEMA DE REGRESIÓN


$$\left\{ ((x_i, y_j), n_{ij}); i = 1, \dots, k, j = 1, \dots, p \right\} \quad n = \sum_{i=1}^k \sum_{j=1}^p n_{ij}, \quad f_{ij} = \frac{n_{ij}}{n}$$

Valores numéricos o marcas de clase

REGRESIÓN DE Y SOBRE X

Determinar una función, f , que permita aproximar, con el menor error posible, los valores de la variable Y a partir de los valores de X , mediante la variable $f(X)$.

- Y : variable dependiente, explicada, endógena o respuesta
- X : variable independiente, explicativa, exógena o regresora



CRITERIO DE MÍNIMOS CUADRADOS

Error cuadrático medio asociado a $f \rightarrow ECM(f) = \sum_{i=1}^k \sum_{j=1}^p f_{ij} (r_{ij}^y)^2 = \sum_{i=1}^k \sum_{j=1}^p f_{ij} (y_j - f(x_i))^2$

Regresión mínimo cuadrática \rightarrow Buscar f tal que $ECM(f)$ es mínimo.

CURVAS DE REGRESIÓN MÍNIMO CUADRÁTICAS

La curva de regresión (mínimo cuadrática) de Y sobre X (similarmente, la de X sobre Y) es la que minimiza el error cuadrático medio asociado:

$$Y/X \rightarrow f(x_1), \dots, f(x_k) / \sum_{i=1}^k \sum_{j=1}^p f_{ij}(y_j - f(x_i))^2 \text{ es mínimo} \Rightarrow f(x_i) = \bar{y}_i = \sum_{j=1}^p f_{j/i} y_j, i = 1, \dots, k.$$

$$X/Y \rightarrow g(y_1), \dots, g(y_p) / \sum_{i=1}^k \sum_{j=1}^p f_{ij}(x_i - g(y_j))^2 \text{ es mínimo} \Rightarrow g(y_j) = \bar{x}_j = \sum_{i=1}^k f_{i/j} x_i, j = 1, \dots, p.$$



CURVA DE REGRESIÓN DE Y SOBRE X		
Puntos:	(x_1, \bar{y}_1)	$\dots (x_k, \bar{y}_k)$
	↓	↓
Frecuencias:	$n_{1.}$	$n_{k.}$



Residuos mínimo cuadráticos
$r_{ij}^y = y_j - \bar{y}_i, i = 1, \dots, k; j = 1, \dots, p$

CURVA DE REGRESIÓN DE X SOBRE Y		
Puntos:	(\bar{x}_1, y_1)	$\dots (\bar{x}_p, y_p)$
	↓	↓
Frecuencias:	$n_{.1}$	$n_{.p}$



Residuos mínimo cuadráticos
$r_{ij}^x = x_i - \bar{x}_j, i = 1, \dots, k; j = 1, \dots, p$

Propiedades de las curvas de regresión mínimo cuadráticas (Y/X)

- La media de los valores ajustados, $\{(\bar{y}_i, n_{i.}); i = 1, \dots, k\}$, coincide con la media de los valores observados:

$$\sum_{i=1}^k f_{i.} \bar{y}_i = \bar{y}.$$

- Los residuos mínimo cuadráticos, $\{(r_{ij}^y, n_{ij}); i = 1, \dots, k, j = 1, \dots, p\}$, tienen media cero y, por tanto, su varianza es el error cuadrático medio asociado a la curva de regresión, que coincide con la media de las varianzas condicionadas:

$$\bar{r}^y = \sum_{i=1}^k \sum_{j=1}^p f_{ij} r_{ij}^y = 0$$

$$\sigma_{ry}^2 = \sum_{i=1}^k \sum_{j=1}^p f_{ij} (r_{ij}^y)^2 = \sum_{i=1}^k f_{i.} \sigma_{y,i}^2 \rightarrow ECM \text{ asociado a la curva.}$$

- La varianza de los valores observados es la suma de la varianza de los valores ajustados y la varianza de los residuos:

$$\sigma_y^2 = \sigma_{ey}^2 + \sigma_{ry}^2, \quad \sigma_{ey}^2 = \sum_{i=1}^k f_{i.} (\bar{y}_i - \bar{y})^2.$$

RECTAS DE REGRESIÓN MÍNIMO CUADRÁTICAS

La recta de regresión (mínimo cuadrática) de Y sobre X (y, análogamente, la de X sobre Y) es, entre todas las rectas, la que minimiza el error cuadrático medio:

$$Y/X \rightarrow y = ax + b / \psi(a, b) = \sum_{i=1}^k \sum_{j=1}^p f_{ij} [y_j - (ax_i + b)]^2 \text{ es mínimo}$$

$$\left. \begin{array}{l} \frac{\partial \psi(a, b)}{\partial a} = 0 \\ \frac{\partial \psi(a, b)}{\partial b} = 0 \end{array} \right\} \rightarrow \begin{array}{l} \text{Ecuaciones normales} \\ m_{11} = am_{20} + bm_{10} \\ m_{01} = am_{10} + b \end{array} \Rightarrow a = \frac{\sigma_{xy}}{\sigma_x^2}, \quad b = \bar{y} - \frac{\sigma_{xy}}{\sigma_x^2} \bar{x}.$$

$$X/Y \rightarrow x = cy + d / \sum_{i=1}^k \sum_{j=1}^p f_{ij} [x_i - (cy_j + d)]^2 \text{ es mínimo} \Rightarrow c = \frac{\sigma_{xy}}{\sigma_y^2}, \quad d = \bar{x} - \frac{\sigma_{xy}}{\sigma_y^2} \bar{y}.$$

RECTA DE REGRESIÓN DE Y SOBRE X
$y = \bar{y} + \frac{\sigma_{xy}}{\sigma_x^2} (x - \bar{x})$
Coeficiente de regresión lineal: $\gamma_{y/x} = \frac{\sigma_{xy}}{\sigma_x^2}$



Residuos lineales mínimo cuadráticos $r_{ij}^{Ly} = y_j - (\bar{y} + \frac{\sigma_{xy}}{\sigma_x^2} (x_i - \bar{x}))$

RECTA DE REGRESIÓN DE X SOBRE Y
$x = \bar{x} + \frac{\sigma_{xy}}{\sigma_y^2} (y - \bar{y})$
Coeficiente de regresión lineal: $\gamma_{x/y} = \frac{\sigma_{xy}}{\sigma_y^2}$



Residuos lineales mínimo cuadráticos $r_{ij}^{Lx} = x_i - (\bar{x} + \frac{\sigma_{xy}}{\sigma_y^2} (y_j - \bar{y}))$

Propiedades de las rectas de regresión mínimo cuadráticas (Y/X)

- Ambas rectas pasan por el centro de gravedad de la distribución, (\bar{x}, \bar{y}) .
- La media de los valores ajustados, $\{(\bar{y} + \frac{\sigma_{xy}}{\sigma_x^2} (x_i - \bar{x}), n_i); i = 1, \dots, k\}$, coincide con la media de los valores observados:

$$\sum_{i=1}^k f_i \left(\bar{y} + \frac{\sigma_{xy}}{\sigma_x^2} (x_i - \bar{x}) \right) = \bar{y}.$$

- Los residuos lineales mínimo cuadráticos, $\{(r_{ij}^{Ly}, n_{ij}); i = 1, \dots, k, j = 1, \dots, p\}$, tienen media cero y, por tanto, su varianza es el error cuadrático medio asociado a la recta:

$$\bar{r}^{Ly} = \sum_{i=1}^k \sum_{j=1}^p f_{ij} r_{ij}^{Ly} = 0 \Rightarrow \sigma_{ry^L}^2 = \sum_{i=1}^k \sum_{j=1}^p f_{ij} (r_{ij}^{Ly})^2 \equiv ECM \text{ asociado a la recta.}$$

- La varianza de los valores observados es la suma de la varianza de los valores ajustados, σ_{xy}^2/σ_x^2 , y la varianza de los residuos:

$$\sigma_y^2 = \sigma_{ey^L}^2 + \sigma_{ry^L}^2, \quad \sigma_{ey^L}^2 = \sum_{i=1}^k f_i \left(\frac{\sigma_{xy}}{\sigma_x^2} (x_i - \bar{x}) \right)^2 = \frac{\sigma_{xy}^2}{\sigma_x^2}.$$

OTROS AJUSTES MÍNIMO CUADRÁTICOS

- **Ajuste de un polinomio de grado arbitrario:** $y = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$

$$a_0, \dots, a_n / \psi(a_0, \dots, a_n) = \sum_{i=1}^k \sum_{j=1}^p f_{ij} [y_j - (a_0 + a_1x_i + a_2x_i^2 + \dots + a_nx_i^n)]^2 \text{ es mínimo}$$

$$\left. \begin{array}{l} \frac{\partial \psi(a_0, \dots, a_n)}{\partial a_0} = 0 \\ \frac{\partial \psi(a_0, \dots, a_n)}{\partial a_1} = 0 \\ \vdots \\ \frac{\partial \psi(a_0, \dots, a_n)}{\partial a_n} = 0 \end{array} \right\} \rightarrow \begin{array}{ll} m_{01} &= a_0 + a_1m_{10} + a_2m_{20} + \dots + a_nm_{n0} \\ m_{11} &= a_0m_{10} + a_1m_{20} + a_2m_{30} + \dots + a_nm_{n+1,0} \\ m_{21} &= a_0m_{20} + a_1m_{30} + a_2m_{40} + \dots + a_nm_{n+2,0} \\ \vdots &\vdots \\ m_{n1} &= a_0m_{n0} + a_1m_{n+1,0} + a_2m_{n+2,0} + \dots + a_nm_{n+n,0} \end{array}$$

- **Ajuste de una hipérbola equilátera:** $y = a/x + b$

Se invierten los valores de X , $x'_i = 1/x_i$; se ajusta una recta a los nuevos datos, $y = ax' + b$, y se deshace el cambio.

- **Ajuste de una función potencial ($X, Y > 0$):** $y = bx^a \rightarrow \log y = a \log x + \log b$

Se transforman los valores de X e Y tomando logaritmos, $x'_i = \log x_i$, $y'_j = \log y_j$; se ajusta una recta a los nuevos datos, $y' = ax' + b'$, y se deshace el cambio.

- **Ajuste de una función exponencial ($Y > 0$):** $y = ba^x \rightarrow \log y = x \log a + \log b$

Se transforman los valores de Y tomando logaritmos, $y'_j = \log y_j$; se ajusta una recta a los nuevos datos, $y' = a'x + b'$, y se deshace el cambio.

RAZONES DE CORRELACIÓN

Cuantifican el grado en que una variable depende de otra, midiendo el grado de ajuste de la correspondiente curva de regresión a la nube de puntos.

Razón de correlación Y/X

$$\eta_{y/x}^2 = \frac{\sigma_{ey}^2}{\sigma_y^2} = 1 - \frac{\sigma_{ry}^2}{\sigma_y^2}$$

- $\sigma_y^2 = \sigma_{ey}^2 + \sigma_{ry}^2 = \sum_{j=1}^p f_j(y_j - \bar{y})^2$
- $\sigma_{ey}^2 = \sum_{i=1}^k f_i(\bar{y}_i - \bar{y})^2$
- $\sigma_{ry}^2 = \sum_{i=1}^k \sum_{j=1}^p f_{ij}(y_j - \bar{y}_i)^2 = ECM(Y/X)$

proporción de σ_y^2 debida a la regresión

$$\eta_{y/x}^2 = 1 - \frac{ECM(Y/X)}{\sigma_y^2}$$

$$ECM(Y/X) = \sigma_y^2(1 - \eta_{y/x}^2)$$

Razón de correlación X/Y

$$\eta_{x/y}^2 = \frac{\sigma_{ex}^2}{\sigma_x^2} = 1 - \frac{\sigma_{rx}^2}{\sigma_x^2}$$

- $\sigma_x^2 = \sigma_{ex}^2 + \sigma_{rx}^2 = \sum_{i=1}^k f_i(x_i - \bar{x})^2$
- $\sigma_{ex}^2 = \sum_{j=1}^p f_j(\bar{x}_j - \bar{x})^2$
- $\sigma_{rx}^2 = \sum_{i=1}^k \sum_{j=1}^p f_{ij}(x_i - \bar{x}_j)^2 = ECM(X/Y)$

proporción de σ_x^2 debida a la regresión

$$\eta_{x/y}^2 = 1 - \frac{ECM(X/Y)}{\sigma_x^2}$$

$$ECM(X/Y) = \sigma_x^2(1 - \eta_{x/y}^2)$$

Propiedades:

- Medidas adimensionales, invariantes frente a cambios de escala y origen en la unidad de medida de la correspondiente variable:

$$\eta_{ay+b/x}^2 = \eta_{y/x}^2, \quad \eta_{ax+b/y}^2 = \eta_{x/y}^2.$$

- $0 \leq \eta_{y/x}^2, \eta_{x/y}^2 \leq 1.$
- $\eta_{y/x}^2 = 0 \Leftrightarrow \sigma_{ey}^2 = 0 \Leftrightarrow \sigma_{ry}^2 = \sigma_y^2 \Leftrightarrow \bar{y}_1 = \dots = \bar{y}_k = \bar{y}.$
 $\eta_{x/y}^2 = 0 \Leftrightarrow \sigma_{ex}^2 = 0 \Leftrightarrow \sigma_{rx}^2 = \sigma_x^2 \Leftrightarrow \bar{x}_1 = \dots = \bar{x}_p = \bar{x}.$
- $\eta_{y/x}^2 = 1 \Leftrightarrow \sigma_{ey}^2 = \sigma_y^2 \Leftrightarrow \sigma_{ry}^2 = 0 \Leftrightarrow Y$ depende funcionalmente de $X.$
 $\eta_{x/y}^2 = 1 \Leftrightarrow \sigma_{ex}^2 = \sigma_x^2 \Leftrightarrow \sigma_{rx}^2 = 0 \Leftrightarrow X$ depende funcionalmente de $Y.$

MEDIDAS DE CORRELACIÓN LINEAL

Cuantifican el grado de relación lineal entre las variables, midiendo el grado de ajuste de las rectas de regresión a la nube de puntos.

Coefficiente de determinación lineal

$$R_{xy}^2 = \frac{\sigma_{xy}^2}{\sigma_x^2 \sigma_y^2}$$

proporción de σ_x^2 y de σ_y^2 debida a la regresión lineal

Coefficiente de correlación lineal

$$R_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

$$R_{xy}^2 = 1 - \frac{ECM^L(Y/X)}{\sigma_y^2} = 1 - \frac{ECM^L(X/Y)}{\sigma_x^2}$$

$$ECM^L(Y/X) = \sigma_y^2(1 - R_{x,y}^2); \quad ECM^L(X/Y) = \sigma_x^2(1 - R_{x,y}^2).$$

Propiedades:

- $R_{xy}^2 = \gamma_{y/x} \gamma_{x/y}$.
- Medidas adimensionales, invariantes frente a cambios de escala (salvo el signo de R_{xy}) y origen en la unidad de medida de cualquiera de las variables:

$$R_{ax+b,cy+d}^2 = R_{x,y}^2.$$

- $R_{xy}^2 \leq \eta_{x/y}^2, \quad R_{xy}^2 \leq \eta_{y/x}^2$.
- $0 \leq R_{xy}^2 \leq 1, \quad -1 \leq R_{xy} \leq 1$.
- $R_{xy}^2 = 0$ ($R_{xy} = 0$) $\Leftrightarrow \sigma_{xy} = 0 \Leftrightarrow$ las rectas de regresión son $y = \bar{y}, x = \bar{x}$.
- $R_{xy}^2 = 1$ ($R_{xy} = \pm 1$) \Leftrightarrow existe dependencia lineal (recíproca) entre X e Y .
- $0 < R_{xy} \leq 1 \rightarrow$ rectas de regresión crecientes.
- $-1 \leq R_{xy} < 0 \rightarrow$ rectas de regresión decrecientes.